

▼ Deskriptivna analiza Airbnb skupa podataka

U ovom dijelu projekta provedena je deskriptivna analiza očišćenog Airbnb skupa podataka.

```
import pandas as pd
import numpy as np

import matplotlib.pyplot as plt
import seaborn as sns

from google.colab import files

uploaded = files.upload()

Odabir datoteka  airbnb_clean.csv
airbnb_clean.csv(text/csv) - 10726166 bytes, last modified: 30. 05. 2026. - 100% done
Saving airbnb_clean.csv to airbnb_clean.csv

df = pd.read_csv("airbnb_clean.csv")
```

Za analizu se koristi prethodno očišćeni skup podataka dobiven u fazi pripreme podataka.

▼ Osnovni pregled podataka

df.head()

	id	name	host_id	host_identity_verified	host_name	neighbourhood_group	neighbourhood	lat	long
0	1001254	Clean & quiet apt home by the park	8.001449e+10	unconfirmed	Madaline	Brooklyn	Kensington	40.64749	-73.75921
1	1002102	Skylit Midtown Castle	5.233517e+10	verified	Jenna	Manhattan	Midtown	40.75362	-73.83021
2	1002755	Water View King Bed Hotel Room	8.509833e+10	unconfirmed	Garry	Brooklyn	Clinton Hill	40.68514	-73.98421
3	1004650	BlissArtsSpace!	6.130061e+10	unconfirmed	Alberta	Brooklyn	Bedford-Stuyvesant	40.68688	-73.97766
4	1006859	Cute & Cozy Lower East Side 1 bdrm	1.280143e+09	verified	Miranda	Manhattan	Chinatown	40.71344	-73.99789

5 rows × 23 columns

```
df.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 51071 entries, 0 to 51070
Data columns (total 23 columns):
 #   Column              Non-Null Count  Dtype  
---  --
 0   id                  51071 non-null  object  
 1   name                51071 non-null  object  
 2   host_id             51049 non-null  float64 
 3   host_identity_verified 51071 non-null  object  
 4   host_name           51071 non-null  object  
 5   neighbourhood_group  51071 non-null  object  
 6   neighbourhood        51071 non-null  object  
 7   lat                 51045 non-null  float64 
 8   long                51045 non-null  float64 
 9   country             51071 non-null  object  
10  country_code        51071 non-null  object  
11  instant_bookable    51071 non-null  bool    
12  cancellation_policy  51071 non-null  object  
13  room_type           51071 non-null  object  
14  construction_year    50958 non-null  float64 
15  price               51071 non-null  float64 
16  service_fee         51071 non-null  float64 
17  minimum_nights      51071 non-null  float64 
18  number_of_reviews    51071 non-null  float64 
19  reviews_per_month   51071 non-null  float64 
20  review_rate_number   51071 non-null  float64
```

```

21 calculated_host_listings_count 51071 non-null float64
22 availability_365                51071 non-null float64
dtypes: bool(1), float64(12), object(10)
memory usage: 8.6+ MB

```

```
df.describe()
```

	host_id	lat	long	construction_year	price	service_fee	minimum_nights	number_of_revie
count	5.104900e+04	51045.000000	51045.00000	50958.000000	51071.000000	51071.000000	51071.000000	51071.0000
mean	4.923543e+10	40.728609	-73.94957	2012.478845	525.931762	105.221065	8.483503	28.6302
std	2.853310e+10	0.056275	0.05032	5.773513	273.955826	54.825779	32.500701	52.0562
min	1.236005e+08	40.499790	-74.24984	2003.000000	50.000000	10.000000	1.000000	0.0000
25%	2.460424e+10	40.688930	-73.98294	2007.000000	288.000000	58.000000	2.000000	2.0000
50%	4.907810e+10	40.722830	-73.95464	2012.000000	527.000000	105.000000	3.000000	8.0000
75%	7.388642e+10	40.763110	-73.93245	2017.000000	762.000000	152.000000	5.000000	31.0000
max	9.876313e+10	40.916970	-73.70522	2022.000000	999.000000	239.000000	5645.000000	1024.0000

Prije detaljnije analize pregledani su osnovni statistički pokazatelji numeričkih atributa te struktura skupa podataka.

Na taj način dobiven je uvid u raspon vrijednosti, srednje vrijednosti te raspoložive attribute koji će se koristiti u daljnjoj analizi.

▼ Distribucija cijena smještaja

```


plt.figure(figsize=(10, 6))

sns.histplot(df["price"], bins=30, kde=True)

plt.title("Distribucija cijena Airbnb smještaja")
plt.xlabel("Cijena")
plt.ylabel("Broj smještaja")

plt.show()

```



Histogram prikazuje raspodjelu cijena Airbnb smještaja u promatranom skupu podataka.

Na temelju grafa može se uočiti u kojem se cjenovnom rasponu nalazi najveći broj oglasa te postoje li smještaji s izrazito visokim ili niskim cijenama.

Ovakva analiza važna je za razumijevanje strukture tržišta i kasnije modeliranje cijena.


Analiza outliera u cijenama

```
plt.figure(figsize=(8, 5))

sns.boxplot(y=df["price"])

plt.title("Boxplot cijena Airbnb smještaja")
plt.ylabel("Cijena")

plt.show()
```




Distribucija ocjena smještaja

```
plt.figure(figsize=(8, 5))

sns.countplot(x="review_rate_number", data=df)

plt.title("Distribucija ocjena smještaja")
plt.xlabel("Ocjena")
plt.ylabel("Broj smještaja")

plt.show()
```



Prikazana je raspodjela ocjena koje su korisnici dodijelili smještajima.

Analiza ocjena omogućuje procjenu opće kvalitete smještaja te uvid u zadovoljstvo korisnika.


▼ Distribucija broja recenzija

```
plt.figure(figsize=(10,6))

sns.histplot(
    df["number_of_reviews"],
    bins=30,
    kde=True
)

plt.title("Distribucija broja recenzija")
plt.xlabel("Broj recenzija")
plt.ylabel("Broj smještaja")

plt.show()
```



Broj recenzija može poslužiti kao pokazatelj popularnosti smještaja. Analizom distribucije moguće je uočiti imaju li većina oglasa mali broj recenzija ili postoje izrazito popularni smještaji s velikim brojem korisničkih ocjena.


▼ Distribucija broja recenzija po mjesecu

```
plt.figure(figsize=(10,6))

sns.histplot(
    df["reviews_per_month"],
    bins=30,
    kde=True
)

plt.title("Distribucija broja recenzija po mjesecu")
plt.xlabel("Broj recenzija po mjesecu")
plt.ylabel("Broj smještaja")

plt.show()
```



Atribut `reviews_per_month` prikazuje koliko recenzija smještaj prosječno dobiva mjesečno. Ovaj atribut predstavlja dobar pokazatelj trenutne aktivnosti i popularnosti smještaja.

✓ Zastupljenost tipova smještaja


```
plt.figure(figsize=(9, 5))

sns.countplot(x="room_type", data=df)

plt.title("Broj smještaja po tipu sobe")
plt.xlabel("Tip smještaja")
plt.ylabel("Broj smještaja")

plt.xticks(rotation=30)

plt.show()
```



Graf prikazuje koliko je zastupljen svaki tip smještaja.

Dobiveni rezultati omogućuju uvid u strukturu Airbnb ponude te pokazuju koji su tipovi smještaja najčešći na tržištu.

✓ Usporedba cijena prema tipu smještaja


```
plt.figure(figsize=(10, 6))

sns.boxplot(x="room_type", y="price", data=df)

plt.title("Cijene prema tipu smještaja")
plt.xlabel("Tip smještaja")
plt.ylabel("Cijena")

plt.xticks(rotation=30)

plt.show()
```



Prikazana je raspodjela cijena za različite tipove smještaja.

Analiza omogućuje usporedbu cjenovnih razlika između cijelih apartmana, privatnih soba i ostalih tipova smještaja.

✓ Prostorna raspodjela oglasa

```
plt.figure(figsize=(9, 5))

sns.countplot(
    x="neighbourhood_group",
    data=df,
    order=df["neighbourhood_group"].value_counts().index
)

plt.title("Broj Airbnb oglasa po gradskim područjima")
plt.xlabel("Gradsko područje")
plt.ylabel("Broj oglasa")

plt.xticks(rotation=30)

plt.show()
```



Graf prikazuje broj Airbnb oglasa po gradskim područjima.

Rezultati pokazuju koja područja imaju najveću koncentraciju smještaja te gdje je Airbnb najzastupljeniji.


✓ Prosječna cijena prema gradskom području

```
avg_price_group = (\n    df.groupby("neighbourhood_group")["price"]\n        .mean()\n        .sort_values(ascending=False)\n)\n\navg_price_group
```

price	
neighbourhood_group	
Bronx	531.965870
Brooklyn	527.847425
Manhattan	525.117483
Queens	521.832845
Staten Island	519.883399

dtype: float64

```
plt.figure(figsize=(9, 5))\n\navg_price_group.plot(kind="bar")\n\nplt.title("Prosječna cijena po gradskom području")\nplt.xlabel("Gradsko područje")\nplt.ylabel("Prosječna cijena")\n\nplt.xticks(rotation=30)\n\nplt.show()
```



Prikazane su prosječne cijene smještaja u pojedinim gradskim područjima.

Ova analiza omogućuje usporedbu atraktivnosti i cjenovne razine različitih dijelova grada.

▼ Najzastupljeniji kvartovi

```
top_neighbourhoods = df["neighbourhood"].value_counts().head(10)

top_neighbourhoods
```

neighbourhood	count
Bedford-Stuyvesant	4055
Williamsburg	3795
Harlem	2740
Bushwick	2301
Hell's Kitchen	2061
Upper West Side	1946
Upper East Side	1823
Midtown	1814
East Village	1686
Crown Heights	1608

dtype: int64


```
plt.figure(figsize=(10, 6))

top_neighbourhoods.plot(kind="bar")

plt.title("Top 10 kvartova po broju Airbnb oglasa")
plt.xlabel("Kvart")
plt.ylabel("Broj oglasa")

plt.xticks(rotation=45)

plt.show()
```

Prikazani su kvartovi s najvećim brojem Airbnb oglasa.

Rezultati pokazuju u kojim dijelovima grada je kratkoročni najam najrazvijeniji.


✓ Odnos cijene i broja recenzija

```
plt.figure(figsize=(10, 6))

sns.scatterplot(
    x="number_of_reviews",
    y="price",
    data=df,
    alpha=0.4
)

plt.title("Odnos cijene i broja recenzija")
plt.xlabel("Broj recenzija")
plt.ylabel("Cijena")

plt.show()
```



Scatter graf prikazuje odnos između cijene smještaja i broja recenzija.

Na temelju prikaza moguće je uočiti postoji li povezanost između popularnosti smještaja i njegove cijene.

✓ Odnos cijene i dostupnosti smještaja

```
plt.figure(figsize=(10, 6))

sns.scatterplot(
    x="availability_365",
    y="price",
    data=df,
    alpha=0.4
)

plt.title("Odnos cijene i dostupnosti smještaja")
plt.xlabel("Dostupnost kroz godinu")
plt.ylabel("Cijena")

plt.show()
```

Odnos cijene i dostupnosti smještaja

Prikazan je odnos između cijene smještaja i njegove godišnje dostupnosti.

Analiza može ukazati na povezanost između cijene i popunjenosti smještaja.

▼ Korelacijska analiza numeričkih atributa

```
numeric_df = df.select_dtypes(include=["number"])

corr = numeric_df.corr()

plt.figure(figsize=(12, 8))

sns.heatmap(
    corr,
    annot=True,
    cmap="coolwarm",
    fmt=".2f"
)

plt.title("Korelacijska matrica numeričkih atributa")

plt.show()
```

