

Sveučilište u Zagrebu
Prirodoslovno-matematički fakultet
Matematički odsjek

Matija Petrović i Tea Kranjec

Analiza karakteristika Airbnb smještaja primjenom metoda dubinske analize podataka

Seminarski rad

Zagreb, 2026.

Sadržaj

1. Uvod	3
2. Opis skupa podataka	4
2.1. Priprema i čišćenje podataka	4
3. Deskriptivna analiza	5
3.1. Osnovni pregled podataka	5
3.2. Distribucija cijena smještaja	5
3.3. Analiza outliera u cijenama	6
3.4. Distribucija ocjena smještaja	6
3.5. Prostorna raspodjela oglasa	7
3.6. Korelacijska analiza numeričkih atributa	7
4. Analiza značajki (Feature engineering)	9
5. Prediktivni modeli	11
5.1. Cilj modeliranja	11
5.2. Priprema podataka	11
5.3. Stablo odlučivanja i Random forest	11
5.4. Napredno modeliranje popularnosti pomoću XGBoost algoritma	13
5.5. Analiza važnosti značajki	14
6. FP-Growth algoritam i asocijacijska pravila	16
6.1. Cilj analize	16
6.2. Priprema podataka za primjenu FP-Growth algoritma	16
6.3. Kodiranje kategorijskih atributa	17
6.4. Pronalaženje frekventnih skupova objekata	17
6.5. Generiranje i analiza asocijacijskih pravila	18
7. Klasteriranje	20
7.1. K-means algoritam	20
7.2. DBSCAN algoritam	22
8. Zaključak	25

1. Uvod

Airbnb jedna je od poznatijih globalnih platformi za kratkoročni najam smještaja koja povezuje privatne iznajmljivače i goste te omogućuje jednostavno oglašavanje i rezervaciju smještajnih jedinica. Razvojem digitalnih platformi tržište kratkoročnog najma posljednjih je godina doživjelo značajan rast, što je rezultiralo stvaranjem velikih količina podataka o smještajima, korisnicima i njihovim interakcijama.

Takvi skupovi podataka predstavljaju vrijedan izvor informacija za primjenu metoda dubinske analize i otkrivanja znanja iz podataka. Samom analizom podataka moguće je identificirati obrasce ponašanja korisnika, istražiti čimbenike koji utječu na uspješnost oglasa te razviti modele za predviđanje različitih karakteristika smještaja. Poseban interes predstavlja i razumijevanje čimbenika povezanih s cijenom i popularnošću smještaja jer upravo oni imaju značajan utjecaj na poslovne odluke iznajmljivača i zadovoljstvo korisnika platforme.

U ovom radu analiziran je skup podataka koji sadrži informacije o Airbnb smještajima u New Yorku preuzet s Kaggle-a. Podaci uključuju karakteristike smještaja, lokaciju, cijenu, dostupnost, broj recenzija, ocjene korisnika te informacije o domaćinima. Na temelju navedenih podataka provedeni su postupci pripreme i čišćenja podataka, deskriptivne analize te konstrukcije novih značajki s ciljem dobivanja dodatnih informacija relevantnih za analizu.

Kako bi se istražila povezanost između pojedinih atributa i karakteristika smještaja, primijenjene su metode prediktivnog modeliranja (stabla odlučivanja, Random Forest i XGBoost), asocijacijska analiza (FP-Growth algoritam) te metode klasteriranja (K-Means i DBSCAN).

2. Opis skupa podataka

U projektu je korišten skup podataka koji sadrži informacije o smještajima dostupnima za najam u New Yorku. On je sadržavao informacije o nazivu smještaja, gradskoj četvrti i naselju u kojem se nalazi, geografskoj lokaciji, vrsti smještaja, cijeni noćenja, naknadi za uslugu, minimalnom broju noćenja, ukupnom broju recenzija te dostupnosti smještaja tijekom godine. Također uključuje podatke o domaćinima, njihovoj aktivnosti te ocjenama i popularnosti pojedinih oglasa. Prilikom početnog pregleda podataka uočeno je da određeni atributi nisu pogodni za analizu. Zbog toga je prije same analize bilo potrebno provesti detaljno čišćenje i pripremu podataka kako bi se osigurala njihova kvaliteta i upotrebljivost.

2.1. Priprema i čišćenje podataka

Prvi korak odnosio se na provjeru kvalitete podataka. Analizirani su nedostajući podaci, tipovi atributa i mogući nekonzistentni zapisi. Utvrđeno je da skup podataka sadrži određeni broj duplikata pa su oni uklonjeni kako bi svaki zapis predstavljao jedinstveni Airbnb oglas.

Tijekom pregleda atributa uočeno je da su varijable *price* i *service_fee* bile zapisane u obliku teksta zbog prisutnosti oznake valute (\$). Kako bi se nad njima mogle provoditi statističke analize, uklonjeni su znakovi \$ te su atributi pretvoreni u numerički oblik. Nakon toga uklonjeni su atributi koji nisu imali značajnu vrijednost za ciljeve projekta, *license* je sadržavao je tehničke oznake, *house_rules* tekstualne opise pravila smještaja, dok je *last_review* predstavljao datum posljednje recenzije, koji nije bio važan za daljnju analizu.

Što se tiče nedostajućih vrijednosti, kod numeričkih atributa one su zamijenjene medijanom, dok je kod kategorijskih atributa korišten mod. Takav pristup omogućio je zadržavanje većine podataka bez gubitka velikog broja zapisa. Također su pronađene nelogične vrijednosti u pojedinim atributima. Primjerice, atribut *minimum_nights* sadržavao je negativne vrijednosti, dok je atribut *availability_365* imao vrijednosti manje od 0 ili veće od 365 dana. Budući da takve vrijednosti nemaju stvarno značenje, označene su kao nedostajuće i zamijenjene na gore opisani način. Nakon provedenih koraka dobiven je očišćen i konzistentan skup podataka spremljen u datoteku *airbnb_clean.csv*. Taj skup podataka korišten je za sve daljnje analize i modeliranje te predstavlja kvalitetnu osnovu za istraživanje karakteristika Airbnb smještaja u New Yorku.


3. Deskriptivna analiza

3.1. Osnovni pregled podataka

Nakon čišćenja podataka dobiven je skup koji sadrži 51 071 Airbnb oglas i 23 atributa. Podaci uključuju informacije o lokaciji smještaja, cijeni, recenzijama, ocjenama korisnika, dostupnosti tijekom godine te karakteristikama domaćina.

Prosječna cijena smještaja iznosi 525,93 USD, dok se cijene kreću od 50 do 999 USD. Medijan cijene iznosi 527 USD, što pokazuje da nema velikog odstupanja između prosječne i tipične vrijednosti. Prosječan broj recenzija iznosi 28,63, pri čemu pojedini oglasi imaju više od 1000 recenzija. Skup podataka sadrži dovoljno velik broj oglasa i raznolike informacije za daljnju analizu tržišta Airbnb smještaja.


3.2. Distribucija cijena smještaja



Slika 1. Distribucija cijena smještaja

Raspodjela cijena pokazuje veliku raznolikost Airbnb ponude. Analizom distribucije cijena uočeno je da cijene pokazuju gotovo uniformnu raspodjelu te vrlo slabu povezanost s atributima koji bi u stvarnim tržišnim uvjetima trebali imati značajan utjecaj na cijenu (tip smještaja, lokacija i sl.). Navedeno upućuje na mogućnost da cijene ne odražavaju stvarne tržišne vrijednosti te ograničava mogućnost izgradnje pouzdanih modela za njihovo predviđanje.


3.3. Analiza outliera u cijenama



Slika 2. Boxplot dijagram

Boxplot pokazuje da se polovica oglasa nalazi između približno 288 USD i 762 USD, dok je medijan oko 527 USD. Nije uočen veći broj izraženih ekstremnih vrijednosti.


3.4. Distribucija ocjena smještaja



Slika 3. Distribucija ocjena smještaja

Prema Slici 3., većina smještaja ima ocjene između 2 i 5, dok je ocjena 1 znatno rjeđa. Rezultati pokazuju da je najveći dio oglasa ocijenjen zadovoljavajuće.


3.5. Prostorna raspodjela oglasa



Slika 4. Prostorna raspodjela

Najveći broj oglasa nalazi se u Manhattanu i Brooklynu, dok su ostali dijelovi grada slabije zastupljeni. Rezultat potvrđuje da je Airbnb ponuda najkoncentriranija u turistički najatraktivnijim dijelovima New Yorka.

3.6. Korelacijska analiza numeričkih atributa



Slika 5. Korelacijska analiza numeričkih atributa

Korelacijska matrica korištena je za analizu povezanosti između numeričkih atributa. Najizraženija povezanost uočena je između atributa *price* i *service_fee*, što je očekivano jer je naknada za uslugu povezana s cijenom smještaja.

Većina ostalih korelacija je slaba, što sugerira na činjenicu da cijenu i popularnost oglasa određuje kombinacija više različitih čimbenika.

4. Analiza značajki (Feature engineering)

S ciljem povećanja informativnosti podataka i radi kvalitetnije analize podataka, iz postojećih su atributa konstruirane nove značajke. Na taj način su se izdvojile dodatne informacije koje izvorni skup podataka nije sadržavao, ali su bile korisne za daljnju analizu.

Prva konstruirana značajka je *availability_ratio* koja predstavlja omjer broja dana dostupnosti smještaja tijekom godine i ukupnog broja dana u godini. Budući da apsolutni broj dana nije jednostavan za interpretaciju, konstruirana je nova značajka

$$availability_ratio = availability_365/365$$

Na taj način dostupnost je normalizirana na interval od 0 do 1 zbog čega je i lakša za interpretaciju. Vrijednost bliska 1 označava smještaj koji je gotovo uvijek dostupan, dok vrijednost bliska 0 označava smještaj koji je rijetko dostupan za rezervaciju. Ova je značajka korištena u prediktivnim modelima te klasteriranju.

Iz atributa *calculated_host_listings_count*, koji označava broj oglasa koje posjeduje domaćin, definirana je binarna varijabla *professional_host*. Time je omogućeno razlikovanje privatnih iznajmljivača od onih koji upravljaju većim brojem nekretnina. Domaćin je označen kao profesionalni ukoliko posjeduje više od jednog oglasa na platformi, dok su ostali domaćini klasificirani kao privatni iznajmljivači. Cilj ove konstrukcije bio je razlikovati individualne domaćine od profesionalnih iznajmljivača koji upravljaju većim brojem nekretnina. Varijabla je korištena kao ulazna značajka u prediktivnim modelima i postupcima klasteriranja.

Iz geografskih koordinata smještaja (lat i long) izračunata je udaljenost od centra grada, definirana značajkom *distance_to_center*. Lokacija predstavlja jedan od najvažnijih čimbenika pri odabiru smještaja. Smještaji bliže centru grada često ostvaruju veću potražnju i više cijene, zbog čega sama geografska koordinata nije dovoljno interpretabilna. Izračunom udaljenosti od centra dobivena je jedinstvena numerička mjera lokacijske atraktivnosti. Kasnija analiza važnosti atributa pokazala je da je upravo *distance_to_center* jedna od važnijih značajki u Random Forest modelu.

Kako bi se popularnost smještaja opisala jednom numeričkom varijablom, konstruirana je značajka *popularity_score*. Prilikom izračuna korištena su tri atributa: *number_of_reviews*,

reviews_per_month i *review_rate_number*. Budući da navedeni atributi imaju različite raspone vrijednosti, prije kombiniranja provedena je standardizacija pomoću metode Z-score. Standardizacijom su sve varijable transformirane tako da imaju srednju vrijednost 0 i standardnu devijaciju 1. Nakon standardizacije *popularity_score* izračunat je kao zbroj standardiziranih vrijednosti navedenih atributa. Na taj način dobivena je jedinstvena mjera koja istovremeno uzima u obzir ukupni broj recenzija, učestalost novih recenzija i kvalitetu smještaja izraženu kroz ocjene korisnika.

Za svaku četvrt izračunata je prosječna cijena smještaja korištenjem atributa *price*. Rezultat je nova značajka *neighborhood_avg_price*, koja predstavlja prosječnu tržišnu cijenu smještaja unutar određene četvrti. Ova značajka omogućuje usporedbu pojedinog smještaja s lokalnim tržištem umjesto promatranja samo njegove apsolutne cijene.

Na temelju cijene smještaja i prosječne cijene njegove četvrti definirana je značajka *price_diff_neighborhood*:

$$price_diff_neighborhood = price - neighborhood_avg_price$$

Pozitivne vrijednosti označavaju smještaje skuplje od prosjeka svoje četvrti, dok negativne vrijednosti označavaju smještaje čija je cijena ispod lokalnog prosjeka. Ova značajka omogućuje procjenu relativne cjenovne pozicije smještaja unutar njegove okoline te može pomoći u identifikaciji luksuznih ili izrazito povoljnih oglasa.

5. Prediktivni modeli

5.1. Cilj modeliranja

Nakon provedene konstrukcije novih značajki, inicijalni cilj prediktivnog modeliranja bio je identifikacija čimbenika koji utječu na cijenu Airbnb smještaja u New Yorku. Problem je postavljen kao zadatak binarne klasifikacije, pri čemu se predviđa pripada li pojedini smještaj kategoriji visoke ili niske cijene.

Ciljna varijabla *high_price* definirana je na temelju medijana cijene cjelokupnog skupa podataka. Oglasi čija je cijena veća od medijana označeni su vrijednošću 1 (visoka cijena), dok su ostali označeni vrijednošću 0 (niska cijena). Međutim, kao što će kasniji eksperimenti pokazati, ovaj je pristup otkrio dublja strukturna ograničenja u distribuciji samog skupa podataka, što je zahtijevalo redefiniranje cilja modeliranja prema predviđanju kontinuirane ocjene popularnosti smještaja (*popularity_score*).

5.2. Priprema podataka


U analizi podataka i pri izradi modela korištene su izvorne i konstruirane značajke. Kategorijski atributi pretvoreni su u numerički oblik metodom kodiranja oznakama (label encoding) kako bi ih modeli mogli koristiti tijekom treniranja. U model su uključeni sljedeći atributi: *distance_to_center*, *availability_ratio*, *professional_host*, *review_rate_number*, *number_of_reviews*, *minimum_nights*, *room_type_encoded*, *neighbourhood_group_encoded*. Varijabla *popularity_score* posebno je zanimljiva jer je za stabla odlučivanja i Random Forest bila ulazna varijabla, a za XGBoost ciljna.

Podaci su podijeljeni na skup za treniranje i skup za testiranje u omjeru 80 : 20. Kako bi se osiguralo da se pri svakom pokretanju programa dobije ista podjela podataka, korišten je parametar *random_state=42*.

5.3. Stablo odlučivanja i Random forest

Kao bazni model korišteno je stablo odlučivanja (Decision Tree) s dubinom ograničenom na pet razina. Model je ostvario točnost od svega 49,2%, što je statistički lošije od slučajnog nagađanja (bacanja novčića). Preciznost je iznosila 49,3%, uz lažno visok odziv (73,3%), što ukazuje na to

da je model nekritički većinu stanova klasificirao kao skupe. Nakon toga primijenjen je složeniji Random Forest model koji je kombinirao veći broj stabala. Točnost klasifikacije skočila je na 66,4%, uz F1-mjeru od 0,655. Iako je Random Forest pokazao bolju stabilnost, rezultati su i dalje bili nezadovoljavajući za ozbiljniju prediktivnu primjenu.



Slika 6. Važnost atributa u modelu Random Forest za predviđanje cjenovne kategorije Airbnb smještaja

Iz grafikona je vidljivo da najveći doprinos u modelu ima atribut *distance_to_center*, što potvrđuje teoretsku pretpostavku da je geografska lokacija i udaljenost od središta New Yorka ključni faktor povezan s formiranjem cijena. Značajan utjecaj također pokazuju konstruirani atributi *popularity_score* i *availability_ratio*.

S druge strane, značajke poput statusa profesionalnog domaćina (*professional_host*) ili tipa sobe (*room_type*) ostvarile su minimalan doprinos. Upravo je ova niska važnost logički ključnih atributa (poput tipa sobe), uz nisku ukupnu točnost modela, potaknula dublju inspekciju baze podataka.

Detaljnim proučavanjem distribucije cijena u skupu podataka (raspon od 50 do 999 USD, gdje su aritmetička sredina od 525,93 USD i medijan od 527 USD gotovo identični) utvrđeno je da su cijene u ovom sintetičkom skupu raspoređene potpuno uniformno i nasumično. Budući da u

podacima ne postoji stvarni tržišni uzorak koji povezuje lokaciju ili kvalitetu s cijenom, modeli nisu imali matematičku osnovu za učenje pravila.

Zbog ovog uviđaja, u nastavku rada napravljen je zaokret: umjesto predviđanja umjetno generirane cijene, modeliranje je preusmjereno na predviđanje stvarne popularnosti smještaja (*popularity_score*) primjenom naprednijeg pristupa.

5.4. Napredno modeliranje popularnosti pomoću XGBoost algoritma

Za predviđanje točne numeričke vrijednosti popularnosti smještaja primijenjen je suvremeni algoritam XGBoost (konfiguriran s *n_estimators*=150, *max_depth*=6, *learning_rate*=0.08).

U ovom koraku u potpunosti je odbačeno kodiranje oznaka (label encoding) te je primijenjeno one-hot kodiranje tekstualnih varijabli (*room_type*, *neighbourhood_group*, *cancellation_policy*), čime je spriječeno da algoritam tretira kategorijalne podatke kao kontinuirane brojeve. Iz modela su također izbačene nerelevantne varijable koje su predstavljale šum (*professional_host*, *instant_bookable*).

Uspješnost modela mjerena je preko koeficijenta determinacije i prosječne apsolutne pogreške (MAE). Rezultati su prikazani na Slici 7.

--- REZULTATI MODELA ZA POPULARNOST ---
R2 Score (Uspješnost modela): 84.83%
Prosječna pogreška (MAE): 0.36


Slika 7. Rezultati XGBoost-a

XGBoost model ostvario je R^2 score od 84,83%, što znači da uspijeva objasniti gotovo 85% ukupne varijacije u popularnosti Airbnb smještaja na temelju preostalih atributa oglasa. Prilikom interpretacije rezultata XGBoost modela potrebno je uzeti u obzir način na koji je konstruirana ciljna varijabla *popularity_score*. Naime, navedena varijabla definirana je kombinacijom standardiziranih vrijednosti atributa *number_of_reviews*, *reviews_per_month* i *review_rate_number*. Istovremeno su neki od tih atributa korišteni i kao ulazne značajke modela. Stoga ostvareni rezultat od 84,83 % za koeficijent determinacije (R^2) ne treba tumačiti isključivo kao dokaz iznimne prediktivne sposobnosti modela, već i kao potvrdu da model uspješno

prepoznaje odnose između varijabli koje sudjeluju u definiranju same mjere popularnosti. Rezultati pokazuju da odabrane značajke dobro opisuju konstruirani indeks popularnosti, ali ne predstavljaju nužno jednako visoku sposobnost predviđanja stvarne tržišne popularnosti na potpuno novim podacima. Unatoč navedenom ograničenju, analiza važnosti značajki i dalje pruža koristan uvid u čimbenike povezane s popularnošću Airbnb smještaja, pri čemu se lokacija smještaja, posebno pripadnost području Manhattana, pokazala kao jedan od najvažnijih neovisnih prediktora popularnosti.

5.5. Analiza važnosti značajki

Nakon postizanja više prediktivne točnosti, analiziran je unutarnji doprinos značajki donošenju odluka unutar XGBoost modela. Rezultati doprinosa pojedinih atributa prikazani su na Slici 8.



Slika 8. Važnost atributa u XGBoost modelu za predviđanje popularnosti smještaja

Očekivano, najveću težinu u ovome XGBoost modelu za predviđanje popularnosti smještaja imaju atributi *review_rate_number* i *number_of_reviews* jer su izravno matematički sudjelovali u inicijalnoj konstrukciji varijable popularnosti.

Međutim, kao ključni stvarni prediktor popularnosti identificirana je binarna varijabla *neighbourhood_group_Manhattan*. Dakle, pripadnost najatraktivnijoj turističkoj i poslovnoj zoni New Yorka (Manhattanu) ima dominantan samostalni utjecaj na ostvarivanje

visoke popularnosti i privlačenje gostiju na platformi. Za razliku od lokacije, faktori poput politike otkazivanja ili minimalnog broja noćenja pokazali su zanemariv doprinos u donošenju odluka modela.

6. FP-Growth algoritam i asocijacijska pravila

6.1. Cilj analize

Cilj je bio istražiti koje se karakteristike Airbnb oglasa najčešće pojavljuju zajedno. U tu svrhu primijenjen je FP-Growth algoritam za pronalaženje frekventnih skupova te generiranje asocijacijskih pravila.

6.2. Priprema podataka za primjenu FP-Growth algoritma

Za potrebe analize asocijacijskih pravila korišten je skup podataka proširen dodatnim atributima koji opisuju karakteristike smještaja. Budući da algoritam FP-Growth radi nad transakcijskim podacima koji označavaju prisutnost ili odsutnost pojedinih obilježja, bilo je potrebno transformirati numeričke varijable u binarne kategorije.

Iz atributa *review_rate_number* konstruirana je varijabla *highly_rated*. Smještaji s ocjenom većom ili jednakom 4 označeni su vrijednošću 1, dok su ostali označeni vrijednošću 0. Na taj način izdvojeni su smještaji koji imaju visoke korisničke ocjene. Kako bi se razlikovali smještaji s iznadprosječnom dostupnošću, iz atributa *availability_ratio* definirana je binarna varijabla *high_availability*. Smještaji čija je vrijednost bila veća od medijana tog atributa označeni su vrijednošću 1, dok su ostali dobili vrijednost 0. Na temelju atributa *popularity_score*, koji predstavlja mjeru popularnosti smještaja, definirana je varijabla *popular_listing*. Smještaji čiji je *popularity_score* bio veći od medijana označeni su kao popularni i dobili su vrijednost 1, dok su ostali označeni vrijednošću 0. Iz atributa *distance_to_center* konstruirana je varijabla *close_to_center*. Smještaji čija je udaljenost od centra grada bila manja od medijana udaljenosti svih oglasa označeni su vrijednošću 1, dok su ostali označeni vrijednošću 0. Na taj su način izdvojeni smještaji koji se nalaze na atraktivnijim lokacijama. U analizu su uključene i prethodno definirane binarne varijable *professional_host* i *high_price*. Varijabla *professional_host* označava domaćine koji upravljaju s više od jednog oglasa, dok *high_price* označava oglase čija je cijena viša od medijana cijena u promatranom skupu podataka.

Nakon provedene transformacije svaki je smještaj predstavljen skupom obilježja koja opisuju njegove karakteristike. Tako pripremljeni podaci korišteni su kao ulaz za algoritam FP-Growth kojim su identificirani frekventni skupovi obilježja i generirana asocijacijska pravila.

6.3. Kodiranje kategorijskih atributa

Uz prethodno definirane binarne attribute, u analizu su uključeni i kategorijski atributi *room_type*, *neighbourhood_group* i *cancellation_policy*. Budući da algoritam FP-Growth zahtijeva binarni prikaz podataka, nad navedenim atributima provedeno je kodiranje. Svaka kategorija pretvorena je u zaseban binarni atribut koji označava prisutnost ili odsutnost odgovarajuće kategorije u pojedinoj transakciji.

Na taj je način atribut *room_type* razdvojen na objekte *room_type_Entirehome/apt*, *room_type_Privateroom*, *room_type_Sharedroom* i *room_type_Hotelroom*; zatim je atribut *neighbourhood_group* razdvojen na sljedeće objekte: *neighbourhood_group_Manhattan*, *neighbourhood_group_Brooklyn*, *neighbourhood_group_Queens*, *neighbourhood_group_Bronx* i *neighbourhood_group_StatenIsland*, dok je *cancellation_policy* razdvojen na objekte *cancellation_policy_moderate*, *cancellation_policy_strict* i *cancellation_policy_flexible*.

Na taj je način formirana transakcijska matrica pogodna za traženje frekventnih skupova objekata.

6.4. Pronalaženje frekventnih skupova objekata

Nakon pripreme transakcijske baze podataka primijenjen je algoritam FP-Growth uz minimalni prag frekvencije od 0,08. Cilj algoritma bio je pronaći frekventne skupove objekata, odnosno skupove obilježja koji se često pojavljuju zajedno u Airbnb oglasima.

Prema Tablici 1., među frekventnim jednočlanim skupovima najveću frekvenciju imali su objekti *room_type_Entirehome/apt* (53,1 %), *close_to_center* (50,0 %), *high_price* (49,8 %), *popular_listing* (49,1 %), *high_availability* (48,6 %) i *highly_rated* (46,2 %). Rezultati pokazuju da značajan dio Airbnb ponude čine cijeli apartmani te da se približno polovica oglasa nalazi u blizini centra grada. Također je vidljivo da su objekti povezani s popularnošću, cijenom i dostupnošću ravnomjerno zastupljeni u promatranom skupu podataka.

Među frekventnim skupovima objekata na poseban način se ističu sljedeće kombinacije:

close_to_center i *neighbourhood_group_Manhattan* (37,3% transakcija),

popular_listing i *highly_rated* (35,5 % transakcija)

te *room_type_Entire home/apt* i *close_to_center* (30,6 % transakcija)

	support	itemsets
7	0.530532	frozenset({room_type_Entire home/apt})
8	0.499990	frozenset({close_to_center})
0	0.497522	frozenset({high_price})
9	0.491272	frozenset({popular_listing})
1	0.486022	frozenset({high_availability})
2	0.461514	frozenset({highly_rated})
3	0.445744	frozenset({room_type_Private room})
10	0.436066	frozenset({neighbourhood_group_Manhattan})
4	0.398296	frozenset({neighbourhood_group_Brooklyn})
115	0.373298	frozenset({close_to_center, neighbourhood_grou...
29	0.354765	frozenset({popular_listing, highly_rated})
11	0.337271	frozenset({cancellation_policy_moderate})
12	0.331727	frozenset({cancellation_policy_flexible})
5	0.331002	frozenset({cancellation_policy_strict})
108	0.306475	frozenset({close_to_center, room_type_Entire h...
18	0.266627	frozenset({high_availability, room_type_Entire...
116	0.265883	frozenset({room_type_Entire home/apt, neighbou...
15	0.264179	frozenset({high_price, room_type_Entire home/a...
109	0.263140	frozenset({popular_listing, room_type_Entire h...
19	0.259614	frozenset({popular_listing, high_availability})

Tablica 1. Prikaz najfrekventnijih skupova obilježja i njihove potpore

Dobiveni rezultati ukazuju na postojanje karakterističnih obrazaca koji povezuju lokaciju smještaja, njegovu popularnost i vrstu smještaja.

6.5. Generiranje i analiza asocijacijskih pravila

Na temelju pronađenih frekventnih skupova objekata generirana su asocijacijska pravila. Za procjenu njihove kvalitete korištene su mjere *support*, *confidence*. Potpora (*support*) predstavlja udio transakcija koje podupiru određeno pravilo, a pouzdanost (*confidence*) označava vjerojatnost pojave posljedice pravila pod uvjetom da je zadovoljen njegov uvjet.

Dobivena asocijacijska pravila pokazuju da se određeni objekti često pojavljuju zajedno u istim transakcijama. Među pravilima s najvećim vrijednostima *confidence* posebno se ističu objekti *popular_listing*, *highly_rated*, *room_type_Entire home/apt*, *neighbourhood_group_Manhattan* i *close_to_center*. Posebno su česta pravila koja povezuju lokaciju smještaja s njegovom popularnošću i kvalitetom. Primjerice, objekti *neighbourhood_group_Manhattan* i

close_to_center pojavljuju se zajedno u velikom broju transakcija, što potvrđuje važnost lokacije u strukturi Airbnb ponude. Također, objekti *popular_listing* i *highly_rated* često se pojavljuju zajedno, što ukazuje na povezanost između popularnosti smještaja i zadovoljstva korisnika. Važno je naglasiti da asocijacijska pravila ne predstavljaju uzročno-posljedične veze između objekata. Ona pokazuju samo obrasce zajedničkog pojavljivanja karakteristika unutar promatranog skupa podataka.

Uz navedene objekte često se pojavljuju i *close_to_center* te *room_type_Entire home/apt*, što dodatno naglašava važnost lokacije i vrste smještaja.

Rezultati sugeriraju da uspješni Airbnb oglasi svoju popularnost ne duguju samo jednoj karakteristici, već kombinaciji više međusobno povezanih obilježja. Među njima se posebno ističu kvaliteta smještaja, lokacija i vrsta smještaja.


7. Klasteriranje

Cilj je pronaći skupine smještaja koje su međusobno slične prema odabranim atributima. U ovom radu želimo otkriti postoje li različiti tipovi Airbnb smještaja, primjerice luksuzni smještaji, popularni turistički smještaji, povoljniji smještaji ili manje popularni udaljeni smještaji. Za klasteriranje su odabrani atributi koji opisuju ekonomsku, lokacijsku i korisničku dimenziju smještaja. Korišteni su: *price*, *distance_to_center*, *popularity_score*, *availability_ratio*, *review_rate_number*. Ovi atributi zajedno omogućuju grupiranje smještaja prema cijeni, lokaciji, popularnosti i dostupnosti.

7.1. K-means algoritam

Broj klastera određen je korištenjem Calinski-Harabasz indeksa. Ova mjera procjenjuje kvalitetu klasteriranja uspoređujući razdvojenost klastera i homogenost objekata unutar pojedinog klastera. Veće vrijednosti indeksa ukazuju na kvalitetnije klasteriranje.

Rezultati za različite vrijednosti parametra K prikazani su na Slici 9. Najveća vrijednost Calinski-Harabasz indeksa ostvarena je za $K = 2$ (13306,55), nakon čega dolazi do postupnog pada vrijednosti indeksa povećanjem broja klastera.




Slika 9. Calinski-Harabasz analiza

Primjenom K-Means algoritma s dva klastera dobivena je podjela skupa podataka na dvije približno jednako velike skupine, pri čemu klaster 0 sadrži 26 523 oglasa, a klaster 1 ukupno 24

522 oglasa. Razlike u prosječnoj cijeni nisu velike, no klaster 0 ima nešto višu prosječnu cijenu te pozitivno odstupanje od prosječne cijene četvrti, dok klaster 1 ima nešto nižu prosječnu cijenu i negativno odstupanje od lokalnog prosjeka. Osim toga, klaster 0 ima znatno veći prosječan broj recenzija, što upućuje na veću aktivnost i popularnost oglasa u toj skupini. Dobiveni rezultati sugeriraju da K-Means nije razdvojio smještaje isključivo prema cijeni, već prema kombinaciji tržišnih obilježja, uključujući popularnost, relativnu cijenu i lokacijske karakteristike.

Za vizualizaciju rezultata provedena je analiza glavnih komponenti (PCA), kojom je višedimenzionalni prostor značajki reducirana na dvije dimenzije. Na Slici 10. prikazan je raspored smještaja u prostoru prve i druge glavne komponente.



Slika 10. PCA prikaz K-Means klastera

Vidljivo je da su identificirana dva klastera djelomično razdvojena duž prve glavne komponente, dok se određeni dio objekata preklapa. Dobiveni rezultati pokazuju da se Airbnb oglasi mogu tek grubo grupirati u dvije dominantne skupine s različitim karakteristikama, ali i da granica između njih nije oštro definirana. Prisutnost preklapanja očekivana je zbog složene prirode Airbnb tržišta, gdje na cijenu i popularnost smještaja istovremeno utječe velik broj međusobno povezanih čimbenika.


7.2. DBSCAN algoritam

Nakon primjene K-Means algoritma provedena je i analiza pomoću DBSCAN (Density-Based Spatial Clustering of Applications with Noise) algoritma. Razlog korištenja DBSCAN metode bio je dobivanje dodatnog uvida u strukturu podataka bez potrebe za unaprijed definiranim brojem klastera. Za razliku od K-Means algoritma, koji zahtijeva zadavanje broja klastera prije izvođenja analize, DBSCAN automatski pronalazi skupine objekata na temelju njihove gustoće te istovremeno identificira anomalne objekte koji ne pripadaju nijednoj skupini. Za primjenu DBSCAN algoritma bilo je potrebno odrediti dva ključna parametra: ϵ (eps) i MinPts (min_samples). Parametar ϵ definira maksimalnu udaljenost između dviju točaka kako bi se smatrale susjedima, dok MinPts određuje minimalan broj susjednih točaka potreban da bi se neka točka smatrala jezgrenom točkom klastera.

U ovom radu odabrana je vrijednost MinPts = 20. Budući da skup podataka sadrži više od 50 000 Airbnb oglasa, cilj je bio osigurati da identificirani klasteri predstavljaju dovoljno velike i stabilne skupine smještaja. Manje vrijednosti parametra MinPts rezultirale bi formiranjem velikog broja vrlo malih klastera i povećanom osjetljivošću na šum, dok veće vrijednosti mogu otežati prepoznavanje stvarnih skupina podataka. Vrijednost 20 pokazala se kao razuman kompromis između stabilnosti klastera i mogućnosti detekcije anomalnih objekata.

Za određivanje parametra ϵ korišten je k-distance graf, pri čemu je za svaki objekt izračunata udaljenost do njegovog 20. najbližeg susjeda. Nakon sortiranja dobivenih udaljenosti analiziran je oblik krivulje kako bi se identificirala točka najveće promjene nagiba. Na grafu je uočen nagli porast udaljenosti pri vrijednostima približno između 0,8 i 1,5, što ukazuje na prijelaz između gusto povezanih objekata i potencijalnih anomalija.

Na temelju dobivenog k-distance grafa odabrana je vrijednost $\epsilon = 0,8$, koja omogućuje formiranje smislenih klastera uz istovremeno izdvajanje netipičnih smještaja. Odabrani parametri omogućili su uspješnu identifikaciju više klastera različitih veličina te izdvajanje anomalnih oglasa koji odstupaju od dominantnih obrazaca u podacima.




Slika 11. K-distance graf za odabir parametara

U analizi su korištene značajke povezane s cijenom, udaljenošću od centra grada, popularnošću smještaja, dostupnošću te brojem i kvalitetom recenzija. Prije primjene algoritma podaci su standardizirani kako bi sve značajke imale usporediv utjecaj na izračun udaljenosti između objekata. Budući da DBSCAN zahtijeva velik broj izračuna udaljenosti, za ubrzanje izvođenja korišteno je paralelno računanje putem parametra $n_jobs = -1$, čime su iskorištene sve dostupne procesorske jezgre i omogućena analiza cijelog skupa podataka.

Rezultati su pokazali da DBSCAN identificira više klastera različitih veličina te značajan broj objekata označenih kao šum (oznaka -1). Za razliku od K-Means algoritma, koji je podatke podijelio na dvije velike skupine, DBSCAN je otkrio složeniju strukturu podataka i izdvojio smještaje koji odstupaju od dominantnih obrazaca. Analiza prosječnih vrijednosti atributa pokazala je da se objekti označeni kao šum razlikuju prvenstveno prema udaljenosti od centra grada i pokazateljima popularnosti. Ti smještaji imaju najveću prosječnu udaljenost od centra grada, ali istovremeno ostvaruju najveće vrijednosti pokazatelja popularnosti, broja recenzija i broja recenzija po mjesecu. Takav rezultat sugerira postojanje netipičnih oglasa koji uspijevaju privući velik broj gostiju unatoč tome što se nalaze izvan najatraktivnijih gradskih lokacija. Vizualizacija rezultata pomoću metode glavnih komponenti (PCA) pokazala je da se većina smještaja nalazi u zajedničkom području prostora značajki te da između klastera postoji određena

razina preklapanja. Istodobno su uočeni objekti koji se značajno izdvajaju od glavne skupine podataka, što potvrđuje sposobnost DBSCAN algoritma da identificira anomalije i specifične skupine smještaja.



Slika 12. PCA prikaz DBSCAN klastera

Može se zaključiti da je DBSCAN bio posebno koristan za otkrivanje netipičnih i anomalnih smještaja, dok se K-Means pokazao prikladnijim za jasnu segmentaciju tržišta na veće i lakše interpretabilne skupine. Kombinacijom obje metode dobiven je potpuniji uvid u strukturu Airbnb podataka i karakteristike različitih tipova smještaja.

8. Zaključak

U ovom seminarskom radu analizirani su ključni faktori koji povezani s cijenom i popularnošću Airbnb smještaja u New Yorku koristeći različite metode dubinske analize podataka. Najzanimljiviji i najvažniji trenutak u radu dogodio se prilikom treniranja inicijalnih modela za klasifikaciju cijene (Stablo odlučivanja i Random Forest). Iako je Random Forest postigao bolju točnost od pojedinačnog stabla (66,4%), analiza važnosti značajki i niska ukupna točnost natjerale su nas na detaljniju provjeru samih podataka. Otkriven smo ključni problem u skupu podataka: cijene su bile uniformno generirane na Kaggleu, zbog čega ih modeli nisu mogli logički povezati s tipom sobe ili lokacijom. Zbog tog saznanja prebačen je fokus s predviđanja cijene na predviđanje popularnosti smještaja. Korištenjem naprednijeg XGBoost modela postignuta je daleko bolja točnost, čime smo dokazali da se popularnost oglasa može predvidjeti na temelju ocjena, recenzija i lokacije.

Asocijacijska analiza (FP-Growth) i metode klasteriranja (K-Means i DBSCAN) dodatno su potvrdile ove rezultate iz druge perspektive. FP-Growth algoritam je izolirao najčešće kombinacije osobina uspješnih smještaja, pokazavši da su visoke ocjene i popularnost gotovo uvijek vezani uz iznajmljivanje cijelog stana na dobrim lokacijama (unutar Manhattana i blizu centra). K-Means klasteriranje je grubo podijelilo tržište na dvije velike skupine: visoko aktivne i popularne smještaje naspram onih s manjim brojem recenzija. Iako je PCA vizualizacija pokazala da se ti klasteri u stvarnosti dosta isprepliću, podjela je bila korisna za opći pregled tržišta. Na kraju, DBSCAN nam je pomogao da uspješno lociramo specifične anomalije i šum u podacima, odnosno oglase koji se po svojim karakteristikama potpuno razlikuju od uobičajenih standarda na tržištu.

Glavni zaključak ovog rada je da uspjeh i popularnost nekog Airbnb oglasa u New Yorku ne ovise o samo jednom faktoru, već o kombinaciji lokacije, tipa smještaja i zadovoljstva gostiju. Također, ovaj projekt nam je pokazao koliko je u analizi podataka važno kritički preispitivati same podatke i rezultate, jer nas je upravo sumnja u loše prve modele dovela do otkrića lažnih cijena i omogućila nam da rad uspješno privedemo kraju s točnijim i smislenijim XGBoost modelom.